

Predviđanje molekularne značajke *pIC50* korištenjem metoda strojnog učenja

Toni Borina, Ana Francesca Stama, Ana Vrabec

1 Uvod

Kemoinformatika je interdisciplinarno područje koje objedinjuje kemiju i računalnu znanost s ciljem prikupljanja, pohrane, analize i interpretacije kemijskih podataka. Obuhvaća različite aspekte, uključujući modeliranje molekula, predikciju njihovih svojstava te dizajn novih spojeva, što je posebno značajno pri razvoju novih lijekova.

Jedan od ključnih elemenata kemoinformatike je način pretvorbe kemijskih struktura u računalno čitljiv format. **SMILES (Simplified Molecular Input Line Entry System)** je široko prihvaćen način linearnog zapisivanja molekula pomoću ASCII znakova. Ovaj sustav omogućuje jednostavno i nedvosmisleno kodiranje složenih kemijskih struktura u tekstualni oblik, što olakšava njihovu pohranu i manipulaciju u računalnim sustavima. Na primjer, SMILES zapis za etanol je "CCO", gdje slova predstavljaju atome ugljika i kisika, a redoslijed slova opisuje povezanost tih atoma unutar molekule.

Osim prikaza strukture, važno je kvantificirati i opisati različite aspekte molekula kako bi se omogućila njihova usporedba i analiza. **Molekulski deskriptori** su numeričke vrijednosti koje opisuju različite karakteristike molekule, poput molekulske mase, lipofilnosti, polarizabilnosti ili topoloških svojstava. Deskriptori igraju ključnu ulogu u razvoju prediktivnih modela.

Deskriptori se mogu klasificirati prema dimenzijama informacija koje sadrže:

- **0D deskriptori:** Opisuju osnovna svojstva molekule, poput molekulske mase i broja atoma.
- **1D deskriptori:** Obuhvaćaju jednostavne strukturne značajke molekule.
- **2D deskriptori:** Temelje se na topološkim i povezanim svojstvima molekule.
- **3D deskriptori:** Opisuju geometrijske i prostorne karakteristike molekule.

Razumijevanje i primjena SMILES notacije te molekularnih deskriptora temeljni su za učinkoviti razvoj u istraživačkom i industrijskom okruženju.

2 Podaci

Naš inicijalni podatkovni skup sastojao se od 479 redaka, pri čemu je svaki redak predstavljao jednu molekulu i sadržavao dvije značajke:

- **ChEMBL ID:** Jedinstveni identifikator molekule u ChEMBL bazi podataka.
- **pIC50:** Logaritamska transformacija IC50 vrijednosti, koja se koristi za mjerenje lipofilnosti molekule, ključnog svojstva u farmaceutskim i kemijskim istraživanjima.

Podatkovni skup bilo je potrebno proširiti kako bismo ga mogli koristiti za prediktivnu analizu. S tim ciljem proveli smo sljedeće korake:

1. **Dohvaćanje SMILES zapisa:** Koristeći ChEMBL REST API, za svaku molekulu dohvaćen je SMILES zapis, koji predstavlja njenu strukturu u tekstualnom formatu.
2. **Normalizacija SMILES zapisa:** SMILES zapisi su normalizirani u kanonski oblik pomoću biblioteke `rdkit`, čime je osigurana konzistentnost i jednoznačnost prikaza molekula.
3. **Generiranje 3D struktura:** Za svaku molekulu generirane su 3D konformacije uz dodatak vodikovih atoma, optimizaciju geometrije te energetsku minimizaciju koristeći `rdkit` algoritme.
4. **Izračun molekularnih deskriptora:** Pomoću biblioteke `Mordred` izračunati su numerički deskriptori (0D, 1D, 2D i 3D). Ti deskriptori opisuju različite aspekte molekula, kao što su:
 - Osnovna svojstva (npr. molekulska masa, broj atoma).
 - Topološke i povezanosti među atomima.
 - Geometrijske i prostorne karakteristike.

U ovome koraku skup je proširen s 1829 novih značajki.

5. **Čišćenje podataka:** Uklonjeni su deskriptori s nenumeričkim vrijednostima (poput stringova ili nedostajućih vrijednosti) te oni s gotovo konstantnim vrijednostima (95% podudarnosti).
6. **Standardizacija podataka:** Sve numeričke značajke standardizirane su korištenjem Standard Scaler-a kako bi se omogućila usporedivost među značajkama.

Rezultat ovog procesa bio je prošireni skup podataka s ukupno 479 molekula i 844 značajke.

3 Redukcija značajki

S obzirom na to da smo dodavanjem deskriptora dobili skup s izrazito velikim brojem značajki, prije provedbe prediktivne analize započeli smo proces redukcije značajki. Za finalan odabir značajki koristili smo kombinaciju triju različitih pristupa.

Prvi pristup temeljio se na *rekurzivnoj eliminaciji značajki* (RFE), pri čemu je kao estimator korišten ansambl metoda *Random Forest Regressor*. Proces odabira značajki proveden je u nekoliko koraka:

1. Uklonjeni su autokorelacijski deskriptori jer oni ne moraju nužno odgovarati strukturnim ili fizikalnim svojstvima molekule. Ovim korakom uklonjeno je 156 deskriptora.
2. Korištenjem algoritma *Random Forest* izračunata je važnost značajki u odnosu na ciljnu varijablu pIC50. Na temelju tih rezultata, zadržano je 60 značajki s najvećom važnosti kako bi se smanjio broj za daljnju analizu.
3. Pearsonovom korelacijom analizirani su odnosi između značajki. U slučaju da su dvije značajke bile visoko međusobno korelirane, zadržana je ona s većom važnosti prema rezultatima *Random Forest* analize, dok je druga uklonjena. Ovaj korak osigurao je neovisnost odabranih značajki.
4. Na reduciranom skupu značajki primijenjena je metoda *Recursive Feature Elimination with Cross-Validation* (RFE_{CV}), koja omogućuje dodatnu optimizaciju selekcije značajki. Ova metoda iterativno eliminira značajke koje najmanje doprinose točnosti modela.

Drugi i treći pristup za selekciju značajki koristili su različite algoritme za procjenu važnosti značajki: *Automatic Relevance Determination* (ARD) regresiju i *Random Forest Regressor*. Procesi su obuhvaćali sljedeće korake:

1. Modeli (*ARDRegression* i *Random Forest Regressor*) trenirani su na skupu podataka, pri čemu su isključene ciljna i identifikatorske varijable (pIC50, ChEMBL_ID i smiles). Model *ARDRegression* važnost značajki odredio je generiranim koeficijentima(ard.coef_), dok je model *Random Forest Regressor* izračunao važnost značajki korištenjem atributa feature_importances_.
2. Dobivene vrijednosti važnosti značajki normalizirane su kako bi se olakšala daljnja obrada.
3. Prag za značajke s najvećim utjecajem odabran je korištenjem *KneeLocator* algoritma, koji identificira točku "koljena" na grafu sortirane važnosti značajki. Značajke čija je važnost iznad određene prag-vrijednosti uključene su u daljnju analizu.

Normalizirane važnosti značajki dobivene svakim od pristupa su zbrojene te je na njih primjenjen *KneeLocator* algoritam. Na taj način, broj značajki uspješno

je smanjen s početnih 844 na 32 značajke koje su zadržale visoku relevantnost za prediktivnu analizu te nisku međusobnu korelaciju.

Odabrani deskriptori su:

- **Topološki deskriptori:** BalabanJ, BertzCT, CIC0, GGI5, MOMI-Z.
- **Geometrijski deskriptori:** ATSC6se, ATS3v, ATS5d, ATS8d, MPC5.
- **Elektron-vezani deskriptori:** PEOE_VSA9, PEOE_VSA13, SlogP_VSA3, SlogP_VSA10.
- **Fizikalno-kemijski deskriptori:** FilterItLogS, DPSA2, ZMIC0, ZMIC2, SRW09.
- **Ostali deskriptori:** piPC10, SaaCH, n5AHRing, n6AHRing, VSA_EState4, VSA_EState8.

4 Modeli

Za predviđanje pIC50 korišteno je nekoliko različitih modela kako bismo mogli usporediti njihove performanse. Korišteni su linearna regresija, stroj potpornih vektora (SVM), L2 regularizirana regresija, XGBoost, duboka neuronska mreža i konvolucijska neuronska mreža. U nastavku su opisani postupci treniranja i arhitekture modela.

Linearna regresija i stroj potpornih vektora trenirani su bez optimizacije hiperparametara. Za treniranje **L2 regularizirane regresije** optimiran je hiperparametar za snagu regularizacije, no ovaj model davao je loše rezultate. Model **XGBoost** treniran je s optimizacijom hiperparametara te koristeći 3-struku unakrsnu validaciju. Mjera na temelju koje se odabira bolji model u ovom postupku je negativna srednja kvadratna pogreška. Najbolji model imao je parametre postavljene na:

- Udio značaki za svako stablo: 0.3
- Stopa učenja: 0.05
- Maksimalna dubina stabla: 5
- Ukupan broj stabala: 100
- L2 regularizacija težina: 1
- Udio podataka za treniranje svakog stabla: 0.9

Duboka neuronska mreža ima 3 potpuno povezana skrivena sloja dimenzija 32, 64 i 64. Na kraju se nalazi izlazni sloj s jednim neuronom, koji daje predikciju pIC50. Nakon svakog sloja, osim zadnjeg nalazi se ReLU aktivacijska funkcija. Mreža je trenirana koristeći 3-struku unakrsnu validaciju kroz 100 epoha.

Konvolucijska neuronska mreža na početku ima potpuno povezani sloj dimenzije 8. Zatim se nalazi prvi konvolucijski sloj s 4 filtera veličine 5 te se nakon njega nalazi još jedan konvolucijski sloj s 8 filtera veličine 3. Nakon konvolucijskih slojeva izlaz se pretvara u jednodimenzijski vektor te se nalazi potpuno povezani sloj veličine 8. Na kraju se nalazi izlazni sloj s jednim neuronom, koji daje predikciju pIC50. Nakon svakog sloja, osim zadnjeg nalazi se ReLU aktivacijska funkcija. Mreža je trenirana koristeći 3-struku unakrsnu validaciju kroz 200 epoha.

5 Rezultati

Modeli su evaluirani koristeći različite metrike performansi kako bi se procijenila njihova preciznost i sposobnost predikcije. Korištene su 3 metrike:


- **Korijen srednje kvadratne pogreške (Root Mean Square Error, RMSE)** - mjeri prosječnu kvadratnu pogrešku između predviđenih i stvarnih vrijednosti. Naglašava velike pogreške zbog kvadriranja odstupanja. Niže vrijednosti RMSE ukazuju na veću točnost modela.
- **Srednja apsolutna pogreška (Mean Absolute Error, MAE)** - mjeri prosječnu apsolutnu razliku između predviđenih i stvarnih vrijednosti. MAE ne daje toliku težinu ekstremnim vrijednostima kao RMSE. Manje vrijednosti MAE označavaju veću pouzdanost modela.
- **R^2 mjera (koeficijent determinacije)** - procjenjuje koliko dobro model objašnjava varijabilnost stvarnih podataka. R^2 vrijednost bliža 1 označava bolji učinak modela, dok negativne ili niže vrijednosti ukazuju na lošu prilagođenost modela.

Tablica 1 prikazuje rezultate evaluacije treniranih modela na testnom skupu podataka koristeći gore navedene metrike. Od treniranih se modela ističu dva: XGBoost i CNN. Konvolucijska neuronska mreža postiže najmanja odstupanja, odnosno srednja kvadratna pogreška i srednja apsolutna pogreška su najmanje od svih ostalih modela. Samo malo veća odstupanja postiže model XGBoost, ali ovaj model ima značajno veću R^2 mjeru od ostalih modela.

Model	MSE	MAE	R^2
Linearna regresija	0.0377	0.1540	0.2371
SVM	0.0301	0.1368	0.3895
Ridge	0.0352	0.1533	0.3006
XGBoost	0.0268	0.1308	0.4667
DNN	0.0296	0.1393	0.4002
CNN	0.0246	0.1291	0.4189


Tablica 1: Rezultati evaluacije modela.

Na slici 1 prikazana je usporedba stvarnih vrijednosti pIC50 i vrijednosti koje predviđa konvolucijska neuronska mreža. Iz prikazanih grafova možemo zaključiti da model pokazuje tendenciju podcjenjivanja i precjenjivanja u određenim intervalima stvarnih vrijednosti. Ako je prava vrijednost pIC50 manja od 0.2 model vraća vrijednosti koje su veće od toga, dok za prave vrijednosti pIC50 veće od 0.65 model vraća manje vrijednosti.



Slika 1: Rezultat CNN-a na skupu za treniranje i testiranje

Slika 2 prikazuje stvarne i predviđene vrijednosti pIC50 modelom XGBoost na skupovima za treniranje i testiranje.



Slika 2: Rezultat XGBoost-a na skupu za treniranje i testiranje

6 Zaključak

Ovo istraživanje pokazalo je kako se primjenom kemoinformatičkih metoda i strojnog učenja mogu predvidjeti pIC50 vrijednosti molekula, ključne za farmaceutska i kemijska istraživanja. Proces je obuhvatio prikupljanje i obradu podataka, generiranje molekulskih deskriptora te primjenu različitih algoritama strojnog učenja.

Najbolji rezultati dobiveni su koristeći konvolucijsku neuronsku mrežu te XGBoost. Ovi modeli ostvarili su visoku preciznost i pouzdanost u predviđanju ciljne varijable, što potvrđuje njihovu primjenjivost u analizi farmaceutskih spojeva. Dobiveni rezultati pokazuju da primjena metoda strojnog učenja u predikciji svojstava molekula predstavlja učinkovit pristup koji omogućuje postizanje vrlo dobrih rezultata te otvara mogućnosti za daljnje istraživanje i razvoj algoritama u ovom području.